

Programação Avançada

Aula 00: Apresentação da Disciplina

Prof. Eduardo Corrêa Gonçalves

02/03/2026

Sumário

Introdução

O que é Ciência de Dados?

Quais Problemas são Resolvidos pela Ciência de Dados?

A Disciplina Programação Avançada

Tópicos Cobertos pela Disciplina


Python

Ambiente Google Colab

Critério de Avaliação

Introdução (1/4)


- O que é Ciência de Dados?
 - Trata-se da disciplina preocupada com a **análise** e **extração** de conhecimento e informação a partir de conjuntos de dados*.



* Fonte: David J. Hand (2018). "Data Science", Wiley StatsRef-Statistics Reference Online



Introdução (2/4)

- A Ciência de Dados é Interdisciplinar
 - É principalmente uma fusão da **Estatística** e **Ciência da Computação**, com influência de outras disciplinas (ex.: Linguística, Física, ...).



Introdução (3/4)

- **Parceria Estatística-Computação**
 - **Estatística** – fornece ferramentas para:
 - **descrever**,
 - **resumir**,
 - **analisar** e
 - **realizar inferências**
sobre os dados.
 - **Computação** – oferece tecnologias eficientes para:
 - **armazenar**,
 - **organizar**,
 - **recuperar**,
 - **integrar** e
 - **transformar**
os dados.



Introdução (4/4)

- O que Motivou o Surgimento da Ciência de Dados?
 - Basicamente, três fatos / tendências do mundo atual:
 - Disponibilidade de **grandes massas de dados** (em especial, dados observacionais)
 - Necessidade de análise de **dados não-estruturados**.
 - **Investimentos bilionários** de grandes empresas.

Ciência de Dados (1/2)

- Que Problemas são Resolvidos pela Ciência de Dados?
 - Classificação
 - *Clustering* (Agrupamento de Dados)
 - *Outros* (ex.: Regressão, análise de Séries Temporais)
 - Em nosso curso, **vamos criar um classificador do zero** (programa que faz classificação)
 - O classificador será bayesiano (Naïve Bayes)
 - Será implementado utilizando programação orientada a objetos.



Ciência de Dados (2/2)

- **Classificação**


- Processo em que um modelo é utilizado para **inferir a classe** de um **objeto** dentre um conjunto de **classes pré-definidas**

- **Ex.:** Classificador de Spam

- Recebe um e-mail como entrada e, como saída, classifica como Normal ou Spam



Classificador
(modelo treinado)



{*Normal* ou *Spam*}

Saída: uma das
classes possíveis

Entrada: texto do e-mail

Programação Avançada (1/4)

- Ciência de Dados: Sub-áreas / técnicas / ferramentas (relação incompleta...)

Ciencia de Dados

Estatística

Computação

Outras áreas

Classificação – Regressão – Agrupamento – Outros

Redes Neurais CUDA Regexp BERT Grid Search Optimization RStudio
 Programação Paralela Word2Vec NumPy SAS Redes Bayesianas TF-IDF RMSE
 PCA Cadeias de Markov Recursividade
 n-grams Naive Bayes Data Wrangling scikit-learn Python Excel SPADE
 Ontologias SMOTE Apriori POO Hadoop Qwen GPT Keras PLN
 PyTorch SQL Embeddings Matriz de Confusão Ensembles Data Streams
 Deep Learning Algoritmos Genéticos TensorFlow DBSCAN Curva ROC R
 Jupyter Notebook Machine Learning OpenCV Dashboards PLSR k-NN
 Random Forest Estruturas de Dados Árvores de Decisão Llama
 SVM pandas NoSQL GPU

Programação Avançada (2/4)

- Assuntos que estudaremos nesse curso:

Ciencia de Dados

Estatística

Computação

Outras áreas

Classificação – Regressão – Agrupamento – Outros

Redes Neurais CUDA Regexp BERT Grid Search Optimization RStudio
 Programação Paralela Word2Vec NumPy SAS Redes Bayesianas TF-IDF RMSE
 PCA Cadeias de Markov Recursividade
 n-grams Naive Bayes Data Wrangling scikit-learn Python Excel SPADE
 Ontologias SMOTE Apriori POO Hadoop Qwen GPT Keras PLN
 PyTorch SQL Embeddings Matriz de Confusão Ensembles Data Streams
 Deep Learning Algoritmos Genéticos TensorFlow DBSCAN Curva ROC R
 Jupyter Notebook Random Forest Machine Learning OpenCV Dashboards PLSR k-NN
 SVM pandas Estruturas de Dados Árvores de Decisão Llama
 NoSQL GPU

Programação Avançada (3/4)

- **Tópicos da Disciplina**

- Nesta disciplina estudaremos temas ligados aos **aspectos computacionais** da Ciência de Dados.
- O curso é dividido em **3 unidades**:
 - I. Programação Orientada a Objetos (POO)
 - II. Introdução às Estruturas de Dados (EDs)
 - III. Data Frames, Computação Vetorizada e outros temas.
- O curso também aborda alguns conceitos de Machine Learning e IA, porém não é o foco.
- Esses temas são cobertos em outras disciplinas, como Inteligência Computacional e Modelos Lineares Generalizados.

Programação Avançada (4/4)

- **Objetivos das Unidades**

- I. **Programação Orientada a Objetos (POO)**

- Entender e elaborar programas orientados a objeto, tendo por foco aplicações em Ciência de Dados. É a principal unidade do curso

- II. **Introdução às Estruturas de Dados (EDs)**

- Apresentar os vários tipos de EDs e sua relação com a Ciência de Dados.
 - Elaborar programas com as EDs nativas do Python.
 - Programar as EDs clássicas da Ciência da Computação (lista encadeada, pilha, fila, árvore e grafo)

- III. **DataFrames, Computação Vetorizada e outros temas**

- Elaborar programas para realizar o *data wrangling* (exploração) de bases de dados, utilizando EDs dos pacotes 'numpy' e 'pandas'
 - Criar gráficos para exploração de dados com o pacote 'matplotlib'
 - Elaborar programas utilizando técnicas de computação vetorizada e paralelismo.

Python (1/4)

- Nesta disciplina utilizaremos a linguagem **Python**
 - Linguagem de programação de **propósito geral**.
 - Serve para:
 - Ciência de Dados*;
 - Aplicações Web;
 - Scripts de Automação;
 - *E outras aplicações...*



- **FILOSOFIA:**


*Priorizar a construção de programas **simples e legíveis** (“bonitos”) sobre a de programas que, mesmo eficientes, sejam complicados e pouco legíveis (“feios”)*

- A **versão** atual da linguagem é **3.14.3**

* Ao longo deste curso, usarei os termos “Estatística” e “Ciência de Dados” de forma intercambiável.

Python (2/4)

- Python é uma linguagem muito popular na ciência de dados e IA*



- Segundo os resultados da **Stack Overflow 2025 Developer Survey**:
- <https://survey.stackoverflow.co/2025/technology#most-popular-technologies-language-learn-ai>

Python (3/4)

- **Há muitas oportunidades em Ciência de Dados***

WASHINGTON, D.C. — The demand for employees with data science skills will continue to grow, according to a recent survey of U.S. workplace managers. Nearly six in 10 managers in the U.S., 57%, say it is "very" (26%) or "somewhat" (31%) likely that they will need to hire more individuals with data science skills in the next five years.

Most U.S. Managers Will Need to Hire More Individuals With Data Science Skills in Next 5 Years

*Thinking about the next five years, how likely is it that your team or department will need to hire more individuals than you currently have with math skills in the following areas? **Data science (e.g., managing, cleaning, interpreting, reporting on data)***

Among managers

■ % Very likely ■ % Somewhat likely ■ % Not very likely ■ % Not at all likely ■ % Don't know



Due to rounding, percentages may sum to 100% $\pm$ 1 percentage point.
Dec. 2-9, 2024

[Get the data](#) • [Download image](#)

These results are from the [Gallup Math Matters Study](#) and are based on separate web surveys of 5,136 U.S. adults and 2,831 workplace managers conducted in December 2024. Workplace managers are defined as employed adults who indicated they are senior leaders, managers, supervisors or project managers responsible for the work output of others.

- <https://news.gallup.com/poll/692312/managers-say-data-science-skills-needed-future.aspx>

Python (4/4)

- Por que a linguagem Python é muito legal para Estatística e IA ?
 - Ela é **interpretada** e pode ser usada de forma **interativa**.
 - No modo interativo, cada comando digitado pode ser imediatamente traduzido e executado.
 - Com isso, resultados intermediários de um processo de análise estatística podem ser examinados em tempo real.
 - É **extensível** através de **pacotes** (*há dezenas de milhares*)
 - NumPy, pandas, scikit-learn, SciPy, Matplotlib, NLTK, Keras, ...
 - É **gratuita** e está disponível no **Google Colab**.
 - É **multiparadigma**.
 - Programação procedural (“tradicional”).
 - Programação orientada a objetos.
 - Programação funcional.

Python – Escolhendo um Ambiente (1/5)

- PASSO 1: Escolher um Ambiente / Distribuição

- Python possui um impressionante ecossistema com dezenas de milhares de pacotes!
 - Isso motivou o surgimento de diversas **distribuições** do ambiente Python.
 - Uma distribuição é um arquivo instalador que reúne:

interpretador Python + standard library (biblioteca padrão) + coleção de pacotes selecionados.

- Cada distribuição é voltada para um propósito específico.
 - Algumas são para Ciência de Dados, outras para desenvolvimento web etc.
 - Por isso, cada distribuição vem com pacotes específicos.

Python – Escolhendo um Ambiente (2/5)

- Neste curso você pode usar as seguintes distribuições:
- **WinPython**: distribuição voltada para Ciência de Dados
 - Boa indicação para os iniciantes
 - **Não requer instalação**, basta descompactar um ZIP em uma pasta do seu computador. A pasta ocupará mais de 4,0GB em disco.
 - Informações em: <https://winpython.github.io/>
 - Download em: <https://sourceforge.net/projects/winpython/files/>
- **CPython**: é a distribuição Python “neutra e oficial”, obtida em www.python.org.
 - É preciso instalar os pacotes para ciência de dados separadamente.
- **Anaconda**: distribuição mais utilizada para ciência de dados.
 - Oferece mais recursos que a WinPython, porém é muito pesada e requer instalação. Muitos alunos gostam.
- *Obs.: Você pode ter WinPython e CPython na mesma máquina. Um não interfere no outro.*


Python – Escolhendo um Ambiente (3/5)

- Porém, é mais fácil utilizar o Google Colab
 - Não requer instalação em sua máquina basta ter uma conta Google!
 - Você escreve o código em seu navegador, gravando seus projetos (chamados “notebooks”) na nuvem.
 - Assim, pode acessá-los de qualquer lugar...
 - Além de poder compartilhar o código com qualquer pessoa.
 - Ambiente inteiramente voltado para Ciência de Dados (principais pacotes estão disponíveis).

Python – Escolhendo um Ambiente (4/5)

- Para começar a trabalhar com Google Colab siga estes passos:

1. Efetue o login em sua conta do Google.
2. Acesse o site <https://colab.research.google.com>
3. Clique em “Novo Notebook”



- Mais informações em:
 - <https://colab.research.google.com/notebooks/intro.ipynb>
 - <https://www.alura.com.br/artigos/google-colab-o-que-e-e-como-usar>

Python – Escolhendo um Ambiente (5/5)

- Quem não utilizar o Colab também deverá escolher um **Ambiente de Desenvolvimento (IDE)**
 - **IDE** (*Integrated Development Environment*) é o software que usamos para criar, testar e executar os programas Python.
 - **Colab** : a IDE já está embutida no ambiente.
 - **WinPython**: vem com o IDLE (python shell), Jupyter e Spyder
 - **CPython**: vem apenas com a python shell, mas você pode instalar a Spyder, Jupyter ou qualquer outra IDE.

Critério de Avaliação (1/4)

- 1. Essas serão as Avaliações:
 - **NOTA DA VAE1:** teste dia 27/4 (matéria dada até 8/4)
 - **NOTA DA VAE2:** trabalho em **grupo de 5 a 6 pessoas** – elaboração módulo para aprimorar classificador que será criado em nosso curso (defesa da ideia + implementação).
 - Descrição do trabalho:
 - Nesse curso, criaremos “do zero” um classificador de texto utilizando o algoritmo Naïve Bayes (versão multinomial). Ele será funcional, porém terá apenas recursos básicos.
 - FASE 1: apresentar ideia de recurso para aprimorar o classificador... torna-lo mais eficiente (rápido) ou eficaz (preciso).
 - O professor irá sugerir diferentes técnicas para os alunos pesquisarem.
 - FASE 2: implementar a ideia e avaliar se realmente aprimorou o classificador.

Critério de Avaliação (2/4)

- 2. Temas para o Trabalho (grupo de até 6 pessoas)
 - Sugestões de temas relacionados à **técnicas para aprimorar o Naïve Bayes**:
 1. Seleção de variáveis com o método Search Forward ou Search Backward
 2. Seleção de variáveis com algoritmos genéticos
 3. Seleção de variáveis com ranking + análise de correlação
 4. Utilizar n -gramas de caracteres em vez de palavras
 5. Utilizar computação vetorizada para aumentar eficiência (rapidez)
 6. *Outro, caso algum grupo faça a sugestão...*

Critério de Avaliação (4/4)

- **4. Implementação (grupo de até 6 pessoas)**
 - Apresentar o módulo criado
 - Apresentar como ele se integra ao Naïve Bayes criado para o curso
 - Rodar o programa e mostrar os resultados.